

Resolução das questões teóricas da Lista 8

Sheila Cássia Janota – 850

1. Digamos que você treinou cinco modelos diferentes com exatamente os mesmos dados de treinamento e todos alcançam 95% de precisão, existe alguma chance de você poder combinar esses modelos para obter melhores resultados? Se sim, como? Se não, por que?

R: Sim. Existe a possibilidade de combinar diferentes modelos para obter melhores resultados utilizando métodos de aprendizagem em conjunto (Ensemble Methods), ou seja combinar os diferentes modelos em um conjunto de votação bagging ou pasting ensemble.

A aprendizagem em conjunto agrupa as predições de modelos diferentes (como classificadores ou regressores), e isso gera melhores resultados de predição.

2. Qual é a diferença entre classificadores de votação rígida e suave?

R: A Votação rígida – conta os votos de cada classificador no conjunto e escolhe a classe que tem o maior número de votos.

A Votação suave – estima a probabilidade média de cada classe e escolhe a classe que possui maior probabilidade. Utilizando o método `predict_proba()` do Scikit-Learn. Geralmente votação suave alcança um desempenho superior em relação a votação rígida, porque a votação suave confere mais peso aos votos de alta confiança, mas funciona apenas se todos os classificadores forem capazes de estimar probabilidades de classe setando `probability=True` no Scikit-Learn.

3. É possível acelerar o treinamento de um bagging ensemble distribuindo-o por vários servidores? E quanto ao pasting ensemble ou floresta aleatória?

R: Sim, é possível acelerar o treinamento de um bagging ensemble distribuindo-o por vários servidores, porque cada classificador (predictor) do conjunto é independente um do outro. E quanto ao pasting ensemble e floresta aleatória também podem acelerar o treinamento em paralelo distribuído por vários servidores pelo mesmo motivo.

4. Qual é o benefício da avaliação out-of-bag?

Out-of-bag instances: são parte das instâncias que não são usadas no treinamento e que não são amostradas.

Cada classificador do bagging ensemble é avaliado por meio de instâncias que não estão sendo usadas no treinamento, e isso faz com que não haja necessidade de separar um conjunto específico para validação.

5. O que torna as árvores-extras (extra-trees) mais aleatórias do que as florestas aleatórias comuns? Como essa aleatoriedade extra pode ajudar? As árvores-extras são mais lentas ou mais rápidas que as florestas aleatórias comuns?

R: - O que torna as árvores-extras (extra-trees) mais aleatórias é o uso de thresholds (limites) aleatórios para cada feature.

- A aleatoriedade extra pode ajudar na melhoria do processo de treinamento, tornando o treinamento muito mais rápido do que nas florestas aleatórias comuns.

- As árvores-extras são mais rápidas que as florestas aleatórias comuns referindo-se ao treinamento, Mas quanto a predição de valores elas não são nem tão rápidas e nem tão lentas.